

# TP – Calibration d’un système multi-caméras OptiTrack

Détection d’une Magic Wand, géométrie épipolaire, reconstruction 3D et calibration métrique

Version 4

## Objectifs du TP


Les systèmes de capture de mouvement OptiTrack utilisent plusieurs caméras infrarouges afin d’observer simultanément des marqueurs rétro-réfléchissants. Les logiciels commerciaux associés à ces systèmes fournissent directement des positions 3D, des objets rigides ou des squelettes. Ces résultats supposent cependant que la géométrie du système de caméras soit connue avec une précision suffisante : paramètres intrinsèques des caméras, distorsion optique, positions et orientations relatives des caméras, échelle métrique et repère global de la scène.

L’objectif de ce TP est de reconstruire une partie de cette chaîne de calibration à partir de données proches des observations brutes du système. Pour chaque caméra et chaque instant synchronisé, les fichiers fournis contiennent les objets 2D détectés par le Camera SDK d’OptiTrack. Ces objets ne sont *pas* préalablement identifiés comme appartenant à la baguette de calibration : les fichiers contiennent donc les détections utiles, mais également les réflexions parasites et autres **faux positifs** ayant franchi les étapes de segmentation réalisées dans la caméra.

Les observations peuvent également contenir des **faux négatifs**. Un ou plusieurs marqueurs de la Magic Wand peuvent être présents dans le champ de la caméra sans apparaître dans la liste des objets détectés, par exemple à cause d’une occultation, d’une réflexion trop faible ou d’une segmentation imparfaite. Une image peut ainsi contenir les trois marqueurs, seulement deux d’entre eux, un seul, ou aucun. Réciproquement, trois objets approximativement alignés ne constituent pas nécessairement les trois marqueurs de la wand : un triplet plausible peut mélanger de vrais marqueurs et du bruit.

Une idée centrale du TP sera donc de **retarder les décisions irréversibles**. Une ambiguïté impossible à résoudre dans une caméra isolée peut devenir simple lorsque l’on utilise simultanément plusieurs caméras et une première estimation de leur géométrie relative.

Le travail suivra une démarche progressive et volontairement itérative :




Le but n’est pas d’appliquer une suite imposée de fonctions de bibliothèque. Pour chaque étape, vous devrez préciser les données utilisées, les hypothèses effectuées, les critères de rejet ou de sélection retenus et les mesures permettant d’évaluer la qualité du résultat.

# 1 Système expérimental et données disponibles

## 1.1 Le système OptiTrack

Le dispositif utilisé pour les acquisitions comporte huit caméras OptiTrack Flex 13. Elles observent une zone commune de la salle et produisent des détections 2D de marqueurs rétro-réfléchissants. Les acquisitions ont été réalisées avec le Camera SDK en mode *ObjectMode*. Les coordonnées enregistrées sont les coordonnées de centroïdes détectées dans les images des caméras. Aucune correction préalable de distorsion n'a été appliquée.

La synchronisation du système fournit des groupes d'images correspondant à un même instant d'acquisition. Toutes les caméras ne sont toutefois pas nécessairement exploitables pour chaque groupe : un marqueur peut être masqué, sortir du champ, ne pas être détecté, ou un groupe peut exceptionnellement être incomplet. Une acquisition multi-caméras ne doit donc pas être pensée comme une matrice rectangulaire dans laquelle toute caméra produit obligatoirement une observation utile à tout instant.




## 1.2 Magic Wand – configuration A

La baguette de calibration est utilisée dans sa **configuration A**. Dans son repère propre, les centres des trois marqueurs sont situés sur un même axe aux abscisses

$$s_0 = 0 \text{ mm}, \quad s_1 = 325 \text{ mm}, \quad s_2 = 500 \text{ mm}.$$

On pourra donc utiliser les distances métriques connues

$$L_{01} = 325 \text{ mm}, \quad L_{12} = 175 \text{ mm}, \quad L_{02} = 500 \text{ mm}.$$



Le marqueur  $M_1$  est le *marqueur intermédiaire* : il est situé entre les deux autres dans l'espace et son image reste située entre les deux images des extrémités lorsqu'elles sont toutes visibles. En revanche,

le rapport entre les longueurs  $M_0M_1$  et  $M_1M_2$  mesurées directement dans l'image n'est pas invariant par projection perspective. La géométrie métrique 325/175 ne doit donc pas être utilisée comme une égalité exacte pour reconnaître la baguette dans une image non calibrée.

### 1.3 Jeux de données

Plusieurs acquisitions indépendantes sont fournies :

| Acquisition                                                | Durée         | Rôle principal possible                                                           |
|------------------------------------------------------------|---------------|-----------------------------------------------------------------------------------|
| scène vide                                                 | 10 s          | caractérisation des faux positifs et du fond                                      |
| Magic Wand fixe $\times 3$                                 | 10 s chacune  | détection, stabilité, validation locale                                           |
| Magic Wand mobile $\times 3$                               | 30 s chacune  | mise au point de la géométrie multi-vues                                          |
| Magic Wand mobile $\times 3$                               | 3 min chacune | calibration robuste et validation sur longue durée                                |
| équerre OptiTrack CS-200 au sol                            | 10 s          | définition du repère physique de la scène                                         |
| veste de motion capture, T-pose                            | 30 s          | application : reconstruction et stabilité d'un nuage 3D de marqueurs              |
| veste de motion capture, déplacements                      | 3 min         | application : reconstruction dynamique des marqueurs en mouvement                 |
| veste, chaussons et bonnet de motion capture, déplacements | 1 min         | application : reconstruction d'un ensemble plus dense et plus étendu de marqueurs |

Les acquisitions réalisées avec la scène vide, la Magic Wand et l'équerre sont destinées à la mise au point et à la calibration du système. Les trois acquisitions de motion capture constituent au contraire des **jeux de données d'application** : elles ne doivent pas être utilisées pour estimer la calibration mais pour exploiter et évaluer le système calibré.

Les acquisitions de calibration n'ont pas nécessairement à être toutes utilisées de la même manière. Vous pourrez, par exemple, distinguer des données servant à la mise au point des seuils, des données servant au calcul des paramètres et des données gardées pour l'évaluation. Votre stratégie devra être explicitée.

## 2 Partie 0 – Compréhension et lecture des données

Chaque répertoire d'acquisition contient plusieurs fichiers texte ou CSV. Le séparateur des fichiers CSV est la virgule. Les nombres flottants sont enregistrés avec une précision élevée afin d'éviter d'introduire une quantification inutile.

### 2.1 Fichier `session.txt`

Le fichier `session.txt` décrit la configuration générale de l'acquisition : nombre de caméras, durée, mode vidéo, présence ou non d'une correction de distorsion, options de synchronisation, puis paramètres de chaque caméra. Pour chaque caméra sont notamment fournis son numéro de série, sa résolution, sa fréquence d'acquisition et certains paramètres de détection utilisés au moment de l'enregistrement.

Ce fichier doit être lu comme un fichier de métadonnées et non comme une source d'observations géométriques.

## 2.2 Fichier `frame_groups.csv`

Chaque ligne décrit un groupe synchronisé. Les colonnes sont :

| Champ                                                             | Signification                                                                                                 |
|-------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------|
| <code>sync_group_id</code>                                        | identifiant local du groupe synchronisé ; c'est la référence principale à utiliser pour relier les fichiers ; |
| <code>host_time_s</code>                                          | temps écoulé côté programme d'acquisition ;                                                                   |
| <code>group_frame_id</code>                                       | identifiant fourni par le groupe synchronisé ;                                                                |
| <code>group_mode</code>                                           | mode de synchronisation signalé par le SDK ;                                                                  |
| <code>received_frame_count</code>                                 | nombre de frames effectivement présentes dans ce groupe ;                                                     |
| <code>expected_camera_count</code>                                | nombre de caméras attendu ;                                                                                   |
| <code>group_timestamp</code>                                      | horodatage du groupe ;                                                                                        |
| <code>group_time_spread</code>                                    | étalement temporel entre les frames composant le groupe ;                                                     |
| <code>earliest_timestamp,</code><br><code>latest_timestamp</code> | bornes temporelles du groupe ;                                                                                |
| <code>dropped_frame_count</code>                                  | nombre de frames signalées comme perdues pour ce groupe.                                                      |

Le fichier `dropped_frames.csv` précise, lorsqu'une perte est signalée, le numéro de série de la caméra concernée.

## 2.3 Fichiers `camera_XX_serial_YYYY_frames.csv`

Un fichier de frames est produit pour chaque caméra. Chaque ligne donne l'état de cette caméra pour un groupe synchronisé. Les champs les plus importants pour ce TP sont :

- `sync_group_id`, qui relie l'enregistrement au groupe global ;
- `camera_index` et `expected_serial`, qui identifient la caméra ;
- `frame_present`, qui indique si une frame a effectivement été reçue ;
- `camera_frame_id` et `camera_timestamp`, identifiants et temps propres à la caméra ;
- `is_empty` et `is_invalid`, qui décrivent l'état de la frame ;
- `object_count`, qui donne le nombre d'objets 2D détectés ;
- les champs `group_time_spread_deviation` et d'horodatage matériel, utiles si vous souhaitez contrôler plus précisément la synchronisation.

Les autres colonnes donnent notamment le numéro de série réellement porté par la frame, l'identifiant de caméra du SDK, la révision matérielle, le type de frame et la région utile de l'image.

## 2.4 Fichiers `camera_XX_serial_YYYY_objects.csv`

Ces fichiers contiennent les observations 2D proprement dites. Une ligne correspond à un objet détecté dans une caméra et un groupe synchronisé. Les colonnes sont :

| Champ                                                                                           | Signification                                                                     |
|-------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|
| <code>sync_group_id</code>                                                                      | groupe synchronisé auquel appartient l'objet ;                                    |
| <code>group_frame_id</code>                                                                     | identifiant SDK du groupe ;                                                       |
| <code>camera_frame_id</code>                                                                    | identifiant de la frame caméra ;                                                  |
| <code>camera_index,</code><br><code>camera_serial</code>                                        | identification de la caméra ;                                                     |
| <code>object_index</code>                                                                       | indice local de l'objet dans la frame ;                                           |
| <code>x_px, y_px</code>                                                                         | coordonnées du centroïde détecté, en pixels ;                                     |
| <code>left_px, right_px, top_px,</code><br><code>bottom_px</code>                               | boîte englobante de l'objet ;                                                     |
| <code>width_px, height_px</code>                                                                | dimensions de la boîte englobante ;                                               |
| <code>area_px, radius_px</code>                                                                 | mesures de taille fournies par le SDK ;                                           |
| <code>aspect, roundness</code>                                                                  | mesures de forme ;                                                                |
| <code>pseudo_label</code>                                                                       | étiquette éventuelle du SDK ; elle n'identifie pas ici les marqueurs de la wand ; |
| <code>flag_active_marker,</code><br><code>flag_predicted,</code><br><code>flag_acquiring</code> | indicateurs fournis par le SDK.                                                   |

Les coordonnées  $(x, y)$  sont des coordonnées **distordues**, telles que détectées dans l'image de la caméra. Aucune transformation géométrique préalable ne doit être supposée.

**Question 0.1.** Construire une représentation interne permettant, pour un `sync_group_id`, d'accéder à la liste des détections de chacune des huit caméras. La représentation choisie devra également permettre d'exprimer explicitement l'absence d'une frame ou l'absence d'objet détecté.

**Question 0.2.** Proposer et produire des statistiques générales pour chaque acquisition : nombre de groupes, taux de présence de chaque caméra, distribution du nombre d'objets détectés et, pour les acquisitions avec wand, fréquence des groupes susceptibles d'être exploitables par plusieurs caméras.

**Question 0.3.** Utiliser l'acquisition de scène vide pour caractériser les détections parasites. Existe-t-il des objets persistants dans certaines zones ? Certains descripteurs de taille ou de forme semblent-ils discriminants ? Éviter toutefois de construire un filtre qui supposerait que tout objet présent dans l'acquisition vide sera toujours parasite dans toutes les acquisitions.


*Élément attendu :* une première visualisation des données, des statistiques de qualité et une description claire de la manière dont les observations multi-caméras sont représentées.

### 3 Partie 1 – Détection de configurations candidates de la Magic Wand

Dans chaque caméra, la projection perspective d'une droite 3D est une droite 2D. Lorsque les trois marqueurs de la wand sont détectés, leurs centroïdes projetés sont donc approximativement colinéaires. Cette propriété constitue un premier invariant géométrique exploitable sans connaître la calibration de la caméra.

### 3.1 Détections complètes, faux positifs et faux négatifs

La recherche d'un triplet colinéaire ne doit pas être confondue avec l'identification certaine de la wand. Plusieurs situations peuvent se présenter pour une même caméra et un même groupe synchronisé.



Une configuration localement plausible n'est qu'une *hypothèse*.  
L'absence de triplet complet ne signifie pas nécessairement que la wand est absente.

Si  $p_a$ ,  $p_b$  et  $p_c$  sont trois points candidats, plusieurs mesures de colinéarité sont possibles. On pourra par exemple considérer l'aire du triangle formé par les trois points, la distance d'un point à la droite définie par les deux autres, ou une distance normalisée tenant compte de l'échelle apparente du triplet. Les tolérances devront être justifiées par les données et non choisies uniquement pour faire fonctionner une acquisition particulière.

La relation d'ordre sur la droite projetée est conservée tant que les trois marqueurs sont détectés. Ainsi, le marqueur  $M_1$  doit apparaître entre les deux extrémités. En revanche, l'une ou l'autre extrémité ne peut pas encore être identifiée de manière fiable comme  $M_0$  ou  $M_2$  à partir de la seule image.

### 3.2 Conserver plusieurs hypothèses

À ce stade, il n'est pas souhaitable de forcer systématiquement la sélection d'un triplet unique. Pour la caméra  $i$  et l'instant  $t$ , on pourra représenter l'ensemble des candidats par


$$\mathcal{T}_i(t) = \{T_i^1(t), T_i^2(t), \dots, T_i^{n_i(t)}(t)\}.$$

Chaque candidat peut être accompagné d'un score local ou de mesures permettant d'en apprécier la plausibilité : erreur de colinéarité, dimensions apparentes, forme des blobs, cohérence avec les données de scène vide, etc.

Un filtrage local reste nécessaire pour éviter une explosion combinatoire. Il faut toutefois distinguer deux opérations :

- éliminer les candidats manifestement incompatibles avec la géométrie attendue ;
- choisir définitivement le candidat correspondant à la wand.

La seconde décision devra autant que possible être retardée jusqu'à ce que l'information multi-vues soit disponible.



### 3.3 Ne pas perdre les observations partielles

Une détection qui ne participe à aucun triplet complet ne doit pas nécessairement être supprimée. Elle est simplement difficile à identifier à ce stade. Après estimation d’une première géométrie multi-vues, une paire de marqueurs, voire une détection isolée, pourra éventuellement être mise en correspondance avec un marqueur de la wand grâce aux contraintes épipolaires et aux autres caméras.

Il est donc conseillé de conserver, en plus de  $\mathcal{T}_i(t)$ , l’ensemble des détections brutes ou au moins celles qui ne sont pas expliquées par un triplet retenu comme candidat.

**Question 1.1.** Proposer une méthode qui, pour une caméra et un groupe synchronisé, produit zéro, un ou plusieurs *triplets candidats*. La méthode devra préciser comment sont utilisés la colinéarité, l’ordre des points et, éventuellement, les descripteurs d’apparence disponibles dans les fichiers.

**Question 1.2.** Définir les informations ou le score local associés à un triplet candidat. Préciser quelles informations servent à éliminer un candidat et lesquelles servent seulement à le classer parmi plusieurs hypothèses plausibles.

**Question 1.3.** Évaluer cette détection sur la scène vide et sur les trois acquisitions avec wand fixe. Examiner non seulement le nombre de triplets produits, mais également leur stabilité temporelle et leur localisation dans l’image.

**Question 1.4.** Sur les acquisitions avec wand mobile, étudier la distribution du nombre de triplets candidats par caméra et par groupe. Identifier des exemples de faux triplets constitués de trois détections parasites ou d’un mélange de vrais marqueurs et de faux positifs. Dans quelles situations aucun triplet complet n’est-il trouvé alors qu’un ou deux marqueurs semblent encore détectés ?

**Question 1.5.** Discuter les risques d’une sélection trop précoce du “meilleur” triplet. Si vous limitez le nombre de candidats conservés, justifier ce choix et vérifier expérimentalement qu’il ne supprime pas trop souvent le véritable triplet.

**Remarque.** Il est possible d’utiliser la continuité temporelle pour favoriser certains candidats, mais elle ne doit pas devenir une hypothèse indispensable : une calibration doit rester possible après une occultation ou lors de la réapparition de la baguette.

*Élément attendu :* pour chaque caméra et chaque groupe, une liste éventuellement vide de triplets candidats, accompagnés d’informations permettant de les comparer, ainsi que la conservation des détections partielles susceptibles d’être réexploitées ultérieurement. Le marqueur intermédiaire doit être distingué des deux extrémités, qui restent à ce stade non orientées.

## 4 Partie 2 – Estimation initiale de la géométrie épipolaire

La matrice fondamentale  $\mathbf{F}_{ij}$  relie deux caméras  $i$  et  $j$ . Pour deux observations homologues  $\mathbf{x}_i$  et  $\mathbf{x}_j$  exprimées en coordonnées homogènes,

$$\mathbf{x}_j^T \mathbf{F}_{ij} \mathbf{x}_i = 0.$$

L’observation  $\mathbf{x}_i$  définit dans l’image  $j$  une droite épipolaire

$$\ell_j = \mathbf{F}_{ij} \mathbf{x}_i.$$

Pour construire une première estimation, on utilisera prioritairement le marqueur intermédiaire  $M_1$  des triplets complets. Contrairement aux extrémités, son identité au sein d’un triplet candidat ne présente pas d’ambiguïté gauche/droite.

## 4.1 Une frame peut fournir plusieurs hypothèses de correspondance

Si plusieurs triplets ont été conservés dans la caméra  $i$ , plusieurs positions sont candidates pour représenter  $M_1$ . On notera

$$C_i(t) = \{\mathbf{x}_i^1(t), \dots, \mathbf{x}_i^{p_i(t)}(t)\}$$


l'ensemble des positions candidates du marqueur intermédiaire déduites des triplets de  $\mathcal{T}_i(t)$ . De même, la caméra  $j$  fournit  $C_j(t)$ .

Pour une frame donnée, on ne dispose donc pas nécessairement d'une correspondance unique

$$\mathbf{x}_i(t) \longleftrightarrow \mathbf{x}_j(t),$$

mais d'un ensemble d'hypothèses

$$C_i(t) \times C_j(t).$$



Les  $p_i(t) p_j(t)$  couples possibles d'une même frame ne doivent pas être assimilés à autant d'observations indépendantes.

Une stratégie naïve consistant à injecter toutes les combinaisons comme des correspondances indépendantes peut donner un poids excessif aux frames les plus ambiguës et augmenter artificiellement le nombre d'outliers. La *frame synchronisée* constitue une unité d'information importante : pour une bonne matrice fondamentale, on s'attend à ce qu'au moins une association candidate soit cohérente, et non à ce que toutes le soient.

Une manière de formaliser cette idée, une fois une matrice  $\mathbf{F}$  proposée, est de définir pour la frame  $t$  une erreur du type

$$e_t(\mathbf{F}) = \min_{\substack{\mathbf{x}_i \in C_i(t) \\ \mathbf{x}_j \in C_j(t)}} d_{\text{epi}}(\mathbf{x}_i, \mathbf{x}_j; \mathbf{F}),$$

où  $d_{\text{epi}}$  désigne une erreur épipolaire adaptée. Cette expression n'impose pas à elle seule une méthode d'estimation : elle illustre surtout qu'une frame ambiguë doit être évaluée par la meilleure hypothèse qu'elle contient, plutôt que par la somme aveugle de toutes les combinaisons possibles.

## 4.2 Estimation robuste et décisions retardées

L'estimation initiale de  $\mathbf{F}_{ij}$  doit donc résoudre simultanément deux difficultés :

- certaines frames ne contiennent aucune correspondance correcte ;
- certaines frames contiennent plusieurs hypothèses dont une seule, au mieux, correspond au véritable marqueur  $M_1$ .

Une stratégie robuste de type RANSAC peut être adaptée à cette situation, mais vous devrez préciser ce qui constitue un échantillon, comment les hypothèses sont tirées, comment une frame contribue au


score d'un modèle et comment les correspondances finalement retenues sont utilisées pour ré-estimer la matrice. D'autres stratégies robustes sont possibles.

L'objectif de cette étape n'est pas encore d'obtenir la meilleure matrice fondamentale possible. Il faut obtenir une géométrie suffisamment correcte pour rendre les ambiguïtés locales plus faciles à résoudre dans la partie suivante.

### 4.3 Ne pas exiger huit observations simultanées

Pour estimer  $\mathbf{F}_{ij}$ , seules les observations communes aux caméras  $i$  et  $j$  sont nécessaires. Une frame où la wand fournit des candidats exploitables dans les caméras 0, 1, 3 et 6 peut donc alimenter les estimations  $(0, 1)$ ,  $(0, 3)$ ,  $(0, 6)$ ,  $(1, 3)$ , etc., même si les quatre autres caméras ne fournissent rien d'exploitable.

Il est utile de représenter le système comme un graphe : chaque caméra est un sommet ; une arête entre  $i$  et  $j$  indique qu'un nombre suffisant de *frames communes* est disponible pour contraindre leur géométrie épipolaire. On pourra noter  $N_{ij}$  le nombre de groupes synchronisés pour lesquels  $C_i(t)$  et  $C_j(t)$  sont tous deux non vides. Ce nombre mesure la quantité de frames potentiellement exploitables, et non le nombre total de combinaisons entre candidats.



$N_{ij}$  : nombre de groupes où les deux caméras disposent d'au moins un candidat au marqueur intermédiaire.

Les observations partielles conservées en partie 1 ne sont pas nécessairement utilisées pour amorcer  $\mathbf{F}_{ij}$  : sans géométrie préalable, un point isolé ou une paire de points est généralement difficile à identifier. Elles ne doivent cependant pas être supprimées, car elles pourront redevenir exploitables dès qu'une première géométrie épipolaire sera disponible.

**Question 2.1.** Construire la matrice symétrique  $N = [N_{ij}]$  donnant, pour chaque paire de caméras, le nombre de groupes où au moins un candidat au marqueur intermédiaire est disponible dans les deux images. Visualiser ou commenter le graphe obtenu. Distinguer cette quantité du nombre brut de couples candidats  $|C_i(t)| |C_j(t)|$ .

**Question 2.2.** Proposer une stratégie robuste permettant d'estimer une première matrice fondamentale lorsqu'une même frame peut contenir plusieurs hypothèses de correspondance. Expliquer notamment comment une frame ambiguë contribue au score d'un modèle.

**Question 2.3.** Justifier le nombre minimal de correspondances, les seuils utilisés et le critère d'acceptation d'une matrice estimée. Vérifier que les correspondances retenues sont suffisamment réparties dans les images et dans le temps pour éviter un modèle déterminé par une configuration trop dégénérée.

**Question 2.4.** Une matrice fondamentale est définie à un facteur multiplicatif près et doit être de rang 2. Vérifier les propriétés des matrices obtenues et mesurer leur qualité sur des frames ou des correspondances qui n'ont pas nécessairement servi à leur estimation.

Pour l'évaluation, l'erreur algébrique  $\mathbf{x}_j^T \mathbf{F}_{ij} \mathbf{x}_i$  est simple mais dépend de la normalisation. Préférer une distance géométrique à la droite épipolaire ou l'erreur de Sampson :

$$d_S^2 = \frac{(\mathbf{x}_j^T \mathbf{F}_{ij} \mathbf{x}_i)^2}{(\mathbf{F}_{ij} \mathbf{x}_i)_1^2 + (\mathbf{F}_{ij} \mathbf{x}_i)_2^2 + (\mathbf{F}_{ij}^T \mathbf{x}_j)_1^2 + (\mathbf{F}_{ij}^T \mathbf{x}_j)_2^2}.$$

**Question 2.5.** Identifier quelques frames fortement ambiguës et examiner comment les différentes matrices fondamentales candidates les interprètent. Une bonne estimation doit-elle maximiser le nombre de couples candidats compatibles, ou le nombre de frames pour lesquelles au moins une association cohérente existe ? Argumenter.

**Point d'attention.** Les coordonnées disponibles sont encore distordues. Le modèle fondamental est donc ici une approximation du modèle sténopé idéal. Cette première géométrie doit surtout être suffisamment bonne pour améliorer l'association des observations ; la distorsion sera explicitement prise en compte lors de la calibration métrique finale.


*Élément attendu :* un ensemble de matrices fondamentales initiales, une stratégie explicite de gestion des hypothèses multiples, des statistiques d'inliers/outliers au niveau des frames et des correspondances, une mesure d'erreur épipolaire et un graphe indiquant quelles relations inter-caméras sont effectivement exploitables.

## 5 Partie 3 – Correction des correspondances et désambiguïsation de la wand

Une première géométrie épipolaire permet maintenant de revenir aux observations 2D. Si le marqueur intermédiaire est observé en  $\mathbf{x}_i$  dans la caméra  $i$ , toute observation homologue dans la caméra  $j$  devrait se trouver à proximité de

$$\ell_j = \mathbf{F}_{ij} \mathbf{x}_i.$$

La même idée peut être appliquée aux trois marqueurs du triplet. Une association de triplets entre plusieurs caméras doit être cohérente avec plusieurs contraintes épipolaires simultanément.



### 5.1 Association des triplets

Une caméra peut produire plusieurs triplets candidats dans une même frame. Une décision prise indépendamment caméra par caméra peut donc créer des correspondances incompatibles. Exploiter au contraire l'information fournie par plusieurs relations  $\mathbf{F}_{ij}$ .

**Question 3.1.** Définir un score permettant de comparer plusieurs associations possibles de triplets entre deux caméras. Étendre ensuite, si vous le jugez utile, ce score à trois caméras ou davantage.


**Question 3.2.** Définir des règles de rejet permettant d'écarter un triplet apparemment plausible dans une caméra mais incompatible avec les observations des autres caméras. Mesurer l'effet de cette correction sur le nombre d'observations conservées et sur l'erreur épipolaire.

## 5.2 Réexploitation des observations partielles

Une fois une première géométrie épipolaire disponible, il devient possible de revenir aux détections qui n'avaient pas formé de triplet complet en partie 1. Si un marqueur  $M_k$  est identifié dans la caméra  $i$ , sa correspondance éventuelle dans la caméra  $j$  doit se trouver à proximité de la droite

$$\ell_{j,k} = \mathbf{F}_{ij} \mathbf{x}_{i,k}.$$

Une caméra qui ne détecte que deux marqueurs peut donc encore apporter deux contraintes utiles, à condition que leur identité puisse être établie à l'aide des autres vues. Le même principe peut parfois s'appliquer à une détection isolée, mais avec une ambiguïté naturellement plus forte.



Une frame partielle peut redevenir exploitable dès que la géométrie multi-vues apporte une information d'identification.

**Question 3.3.** Proposer une stratégie permettant de réexaminer les détections partielles à l'aide des matrices fondamentales et des observations des autres caméras. Préciser dans quelles conditions une paire ou un point isolé peut être considéré comme suffisamment identifié pour être réutilisé, et comment éviter de transformer un faux positif isolé en faux marqueur.

## 5.3 Ambiguïté des extrémités

Le marqueur intermédiaire  $M_1$  est identifiable dans une image, mais les extrémités visibles de part et d'autre peuvent correspondre à  $M_0$  ou  $M_2$ . Une inversion locale des extrémités crée une mauvaise correspondance multi-vues.

Deux affectations sont donc à comparer :

$$(m_a, m_b, m_c) \leftrightarrow (M_0, M_1, M_2) \quad \text{ou} \quad (m_a, m_b, m_c) \leftrightarrow (M_2, M_1, M_0).$$

**Question 3.4.** Proposer une méthode multi-vues permettant de lever cette ambiguïté. La géométrie épipolaire peut être utilisée avant même de connaître une reconstruction métrique. Une reconstruction provisoire pourra ensuite fournir une contrainte supplémentaire grâce aux distances connues 325 et 175 mm.

**Question 3.5.** Étudier la cohérence temporelle de l'orientation obtenue. Une inversion occasionnelle d'une seule frame est-elle physiquement plausible ou traduit-elle plutôt une erreur d'association ? Proposer une manière de distinguer continuité utile et contrainte temporelle trop rigide.

*Élément attendu :* un ensemble de correspondances multi-vues nettoyées, incluant lorsque cela est possible des observations partielles ré-identifiées. Les trois marqueurs doivent être distingués autant que possible comme  $M_0$ ,  $M_1$  et  $M_2$ , tout en conservant un moyen d'exprimer qu'une identification reste incertaine ou absente.

## 6 Partie 4 – Ré-estimation de la géométrie épipolaire

Les correspondances utilisées dans la partie 2 étaient volontairement imparfaites. Les associations obtenues à la partie 3 doivent maintenant permettre de recalculer chaque  $\mathbf{F}_{ij}$  avec un jeu de données plus propre et, idéalement, mieux réparti dans l'espace image.

**Question 4.1.** Ré-estimer les matrices fondamentales à partir des correspondances corrigées. Comparer les matrices initiales et affinées au moyen d'indicateurs quantitatifs : nombre de correspondances retenues, distribution de l'erreur de Sampson, quantiles de l'erreur, proportion de points sous un seuil donné.


**Question 4.2.** Vérifier la généralisation sur des séquences ou portions de séquences non utilisées pour sélectionner les paramètres de la méthode. Une diminution de l'erreur sur les données ayant servi au calcul ne suffit pas à démontrer une amélioration réelle.

**Question 4.3.** Le graphe des caméras est-il connexe ? Certaines arêtes semblent-elles nettement moins fiables ? Discuter les conséquences pour la construction ultérieure d'un modèle global du système.

## 7 Partie 5 – Reconstruction 3D initiale et utilisation de la géométrie connue de la wand

Une matrice fondamentale décrit une relation projective entre deux images mais ne fournit pas, à elle seule, une reconstruction métrique complète. La Magic Wand apporte précisément l'information métrique manquante : les distances entre ses marqueurs sont connues.

Après choix d'un modèle de caméras initial et d'un repère de référence, une observation 3D peut être triangulée à partir de deux caméras ou davantage. Dans une approche multi-vues, il est préférable d'utiliser toutes les observations disponibles d'un même marqueur plutôt que d'imposer une paire unique de caméras.



**Question 5.1.** Construire une première reconstruction 3D des trois marqueurs pour les groupes

où suffisamment de caméras fournissent des observations cohérentes. Indiquer comment sont choisies les caméras utilisées et comment sont traitées les observations incompatibles.

**Question 5.2.** Évaluer la reconstruction à l'aide des longueurs de la wand :

$$e_{01} = \left| \|\hat{\mathbf{X}}_0 - \hat{\mathbf{X}}_1\| - 325 \right|, \quad e_{12} = \left| \|\hat{\mathbf{X}}_1 - \hat{\mathbf{X}}_2\| - 175 \right|, \quad e_{02} = \left| \|\hat{\mathbf{X}}_0 - \hat{\mathbf{X}}_2\| - 500 \right|,$$

avec les distances exprimées en millimètres après fixation de l'échelle.

**Question 5.3.** Utiliser les acquisitions de wand fixe pour étudier la stabilité temporelle des positions reconstruites. Pour une pose fixe, mesurer par exemple l'écart-type des coordonnées 3D ou la dispersion autour d'une position moyenne.

**Question 5.4.** Comparer une triangulation fondée sur une paire de caméras seulement avec une triangulation utilisant davantage de vues. Les résultats sont-ils toujours meilleurs lorsque le nombre de caméras augmente ? Discuter le rôle d'une caméra mal calibrée ou d'une mauvaise correspondance.

## 8 Partie 6 – Calibration métrique globale des caméras

La calibration finale doit expliquer simultanément les observations 2D et la géométrie connue de la wand. Pour la caméra  $i$ , on note  $\mathbf{K}_i$  ses paramètres intrinsèques,  $D_i$  ses paramètres de distorsion, et  $(\mathbf{R}_i, \mathbf{t}_i)$  sa pose dans un repère global encore arbitraire. À l'instant  $t$ , la wand possède elle-même une pose  $(\mathbf{R}_w(t), \mathbf{t}_w(t))$ .

Dans le repère propre de la wand, on peut écrire

$$\mathbf{X}_0^w = (0, 0, 0)^\top, \quad \mathbf{X}_1^w = (325, 0, 0)^\top, \quad \mathbf{X}_2^w = (500, 0, 0)^\top \quad (\text{mm}).$$

La position du marqueur  $k$  dans le repère global est alors

$$\mathbf{X}_{k,t} = \mathbf{R}_w(t) \mathbf{X}_k^w + \mathbf{t}_w(t),$$

et son observation idéale dans la caméra  $i$  peut être modélisée par

$$\hat{\mathbf{x}}_{i,k,t} = \pi(\mathbf{K}_i, D_i, \mathbf{R}_i, \mathbf{t}_i, \mathbf{X}_{k,t}).$$

Le problème global peut être formulé comme une minimisation de l'erreur de reprojection sur l'ensemble  $\mathcal{O}$  des observations effectivement disponibles :

$$\min_{\Theta} \sum_{(i,k,t) \in \mathcal{O}} \rho(\|\mathbf{x}_{i,k,t} - \hat{\mathbf{x}}_{i,k,t}(\Theta)\|^2),$$

où  $\Theta$  regroupe les paramètres de caméras et les poses de la wand, et  $\rho$  peut être une pénalisation robuste. Cette écriture montre qu'il n'est pas nécessaire que les huit caméras observent les trois marqueurs à chaque instant : seules les observations réellement disponibles contribuent à la somme. À ce stade, dès lors que l'identité d'un marqueur est suffisamment fiable, **une observation 2D individuelle est déjà une contrainte utile**. Une caméra observant deux marqueurs apporte donc deux termes de reprojection ; une caméra n'en observant qu'un seul peut encore contribuer avec un terme. L'exigence d'un triplet complet était principalement nécessaire pour amorcer l'identification avant que la géométrie du système soit connue.

## 8.1 Modèle de distorsion

Les coordonnées enregistrées n'ont pas été corrigées de leur distorsion. Vous devrez donc choisir et expliciter un modèle. Un modèle radial simple peut par exemple écrire, dans des coordonnées normalisées,

$$x_d = x \left( 1 + k_1 r^2 + k_2 r^4 + \dots \right), \quad y_d = y \left( 1 + k_1 r^2 + k_2 r^4 + \dots \right),$$

avec  $r^2 = x^2 + y^2$ . Un modèle radial-tangentiel plus complet peut également être utilisé. Le nombre de coefficients introduits doit rester compatible avec la quantité et la diversité géométrique des données disponibles.

## 8.2 Deux hypothèses à comparer

Vous étudierez au minimum les deux modèles suivants.

**Modèle A – intrinsèques partagés.** Les huit caméras étant du même modèle, on impose

$$\mathbf{K}_i = \mathbf{K}, \quad D_i = D$$

pour toutes les caméras, tandis que les extrinsèques  $(\mathbf{R}_i, \mathbf{t}_i)$  restent propres à chaque caméra.

**Modèle B – intrinsèques indépendants.** Chaque caméra possède ses propres paramètres

$$\mathbf{K}_i, \quad D_i, \quad \mathbf{R}_i, \quad \mathbf{t}_i.$$

Ce modèle comporte davantage de degrés de liberté et peut donc diminuer l'erreur d'ajustement, mais cette diminution doit être interprétée avec prudence.

**Question 6.1.** Établir précisément la liste des inconnues de chacun des deux modèles et les degrés de liberté qu'il faut fixer pour éliminer les ambiguïtés globales de repère.

**Question 6.2.** Proposer une initialisation des extrinsèques à partir des relations épipolaires et du graphe de caméras obtenu précédemment. Une caméra peut être choisie comme référence temporaire. Discuter l'intérêt d'un arbre couvrant privilégiant les arêtes les plus fiables plutôt qu'une propagation arbitraire.

**Question 6.3.** Estimer les paramètres du modèle A, puis du modèle B. Le résultat final doit être obtenu à partir d'une optimisation multi-vues utilisant les observations de la wand et ses dimensions connues.

**Question 6.4.** Comparer les deux modèles sur des données n'ayant pas servi au réglage. Le modèle indépendant apporte-t-il une amélioration significative de l'erreur de reprojection ou de reconstruction 3D ? Les paramètres intrinsèques estimés pour les différentes caméras sont-ils physiquement plausibles et cohérents ?

## 9 Partie 7 – Définition du repère physique de la scène

La calibration précédente permet de reconstruire la scène à une échelle métrique, mais le choix du repère global reste arbitraire. La dernière acquisition contient une équerre OptiTrack immobile, posée au sol. Sa géométrie permet de définir l'origine et les directions du repère physique de la salle.

## 9.1 Géométrie de l'équerre OptiTrack CS-200

On considérera dans ce TP une équerre OptiTrack **CS-200** comportant trois marqueurs : un marqueur à l'origine de l'équerre, un marqueur à l'extrémité d'une première branche de longueur 150 mm, et un marqueur à l'extrémité d'une seconde branche de longueur 200 mm. Dans le repère propre de l'équerre, on pourra par exemple modéliser ces trois points par


$$E_0 = (0, 0, 0), \quad E_1 = (150, 0, 0), \quad E_2 = (0, 200, 0) \quad \text{mm.}$$

Les longueurs connues sont donc

$$\|E_0 - E_1\| = 150 \text{ mm}, \quad \|E_0 - E_2\| = 200 \text{ mm}, \quad \|E_1 - E_2\| = 250 \text{ mm}.$$

La dernière distance est déduite du théorème de Pythagore et fournit une vérification métrique simple de la reconstruction obtenue.

Équerre OptiTrack CS-200 :  
origine  $E_0$ , branche courte 150 mm, branche longue 200 mm.




Après reconstruction des trois marqueurs, on peut identifier une origine  $O = E_0$ , un point  $P_X = E_1$  définissant la direction d'un premier axe du plan du sol et un point  $P_Y = E_2$  définissant une seconde direction du plan. On obtient alors

$$\mathbf{e}_X = \frac{P_X - O}{\|P_X - O\|}, \quad \tilde{\mathbf{e}}_Y = \frac{P_Y - O}{\|P_Y - O\|}.$$

Pour obtenir un repère orthonormé, on pourra orthogonaliser la seconde direction puis définir

$$\mathbf{e}_Z = \mathbf{e}_X \times \mathbf{e}_Y.$$

Le signe de  $\mathbf{e}_Z$  doit être choisi de manière cohérente avec le sens vertical attendu.



**Question 7.1.** Identifier et reconstruire les trois marqueurs utiles de l'équerre CS-200. Comme elle reste fixe pendant 10 s, exploiter la redondance temporelle pour améliorer la précision, détecter les observations aberrantes et vérifier que les trois distances reconstruites sont compatibles avec 150 mm, 200 mm et 250 mm.

**Question 7.2.** Construire la transformation rigide faisant passer du repère arbitraire de calibration au repère défini par l'équerre. Appliquer cette transformation aux positions et orientations des caméras.

**Question 7.3.** Vérifier que l'équerre reconstruite est bien coplanaire et que le plan correspondant devient un plan de référence cohérent avec le sol après changement de repère. Discuter les limites éventuelles de cette définition du repère global.

*Élément attendu :* une définition explicite du repère physique de la scène, fondée sur la géométrie connue de l'équerre CS-200, ainsi qu'une transformation rigide appliquée à l'ensemble des caméras et, éventuellement, aux reconstructions 3D produites précédemment.


## Question subsidiaire – Visualisation 3D de marqueurs de motion capture

Une fois le système calibré et exprimé dans le repère physique défini par l'équerre CS-200, trois acquisitions supplémentaires permettent d'appliquer la chaîne précédente à des données de motion capture plus proches d'une utilisation réelle :

- une veste de motion capture en T-pose pendant 30 s ;
- une veste de motion capture portée pendant des déplacements durant 3 min ;
- une veste complétée par des chaussons et un bonnet de motion capture, pendant des déplacements durant 1 min.

Contrairement à la Magic Wand, ces acquisitions comportent un nombre plus important de marqueurs et aucune géométrie rigide unique n'est fournie pour les identifier. L'objectif n'est donc pas, dans cette question, de reconstruire automatiquement un squelette ou d'attribuer une identité anatomique à chaque marqueur. On cherchera d'abord à reconstruire, pour chaque groupe synchronisé, un **ensemble de points 3D non étiquetés** aussi cohérent que possible.

Pour une observation 2D donnée dans une caméra, les matrices fondamentales permettent de rechercher des observations compatibles dans les autres caméras. Une hypothèse de correspondance multi-vues pourra ensuite être triangulée et évaluée par son erreur de reprojection. Les mêmes difficultés que précédemment restent présentes : faux positifs, marqueurs temporairement masqués, détections manquantes et ambiguïtés lorsque plusieurs marqueurs sont proches les uns des autres.



Après calibration : correspondances multi-vues, triangulation et visualisation d'un nuage de marqueurs 3D évoluant au cours du temps.

**Question S.1.** À partir de la calibration obtenue dans les parties précédentes, proposer une méthode permettant de construire, pour chaque groupe synchronisé, un ensemble de marqueurs 3D à partir des détections disponibles dans plusieurs caméras. Décrire comment sont générées les hypothèses de correspondance, comment une reconstruction est validée et comment sont traitées les observations incompatibles ou insuffisamment contraintes.

**Question S.2.** Réaliser une visualisation 3D animée des marqueurs reconstruits dans le repère physique de la scène. La représentation devra au minimum faire apparaître le nuage de points courant et le plan du sol ; la position des caméras peut également être affichée afin de faciliter l'interprétation des erreurs et des occultations.

**Question S.3.** Exploiter l'acquisition en T-pose, qui est approximativement statique, pour caractériser la stabilité de la reconstruction : nombre de marqueurs reconstruits par frame, dispersion temporelle des positions, erreur de reprojection et apparition éventuelle de points 3D aberrants ou "fantômes". Cette acquisition peut-elle fournir une validation complémentaire de la calibration obtenue avec la wand ?

**Question S.4.** Appliquer ensuite la même chaîne aux deux acquisitions en déplacement. Comparer la séquence utilisant uniquement la veste à celle utilisant également les chaussons et le bonnet. Discuter notamment l'effet du nombre et de la répartition spatiale des marqueurs, des occultations, du mouvement et des ambiguïtés de correspondance sur la qualité de la reconstruction 3D.

**Prolongement facultatif.** Une fois les marqueurs reconstruits frame par frame, il est possible d'étudier leur association temporelle afin de construire des trajectoires 3D. Cette étape est distincte de la triangulation multi-vues : elle pose un nouveau problème de suivi et d'identification dans le temps et n'est pas nécessaire pour répondre à la question subsidiaire.

*Élément attendu :* une visualisation 3D exploitable des trois acquisitions de motion capture et une analyse qualitative et quantitative de la stabilité, des pertes de marqueurs, des points aberrants et de l'influence du mouvement.